



**INSTITUT TEKNOLOGI SUMATERA**  
**Program Studi Teknik Informatika**

**TUGAS BESAR MAHADATA**

**Analisis Big Data Aktivitas Gempa Bumi Menggunakan Apache  
Spark dan Dashboard Interaktif**

**Mata Kuliah: IF25-40402 / Mahadata**  
Semester Genap 2025/2026

|                            |                                                                                                                                                                                                                                                                           |
|----------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Kelompok</b>            | Kelompok 3                                                                                                                                                                                                                                                                |
| <b>Bidang Topik</b>        | Kebencanaan                                                                                                                                                                                                                                                               |
| <b>Anggota Kelompok</b>    | 1. Nabila Ramadhani Mujahidin - 123140062<br>2. Annisa Salsabila - 123140070<br>3. Willy Syifa Luhtfia - 123140071<br>4. Roberto Charlos Sagala - 123140113<br>5. Brahmantio Abimayu - 123140122<br>6. Zacky Ghazi Al Miqdad - 123140130<br>7. Albi R. Suseno - 120140095 |
| <b>Tanggal Pengumpulan</b> | 29 Mei 2026                                                                                                                                                                                                                                                               |

**2026**

## Abstrak

Penelitian ini membangun sebuah platform Big Data Analytics end-to-end untuk monitoring dan analisis aktivitas seismik berbasis dataset USGS Earthquake Catalog. Berbeda dari pendekatan deep learning konvensional yang hanya berjalan pada satu mesin, implementasi ini mengadopsi arsitektur terdistribusi yang sesungguhnya menggunakan tiga komponen inti Big Data: Apache Kafka sebagai message broker untuk ingestion data, Apache Spark (dengan PySpark) sebagai distributed processing engine, dan Hadoop HDFS sebagai distributed storage dalam format Parquet. Analitik dilakukan menggunakan Spark MLlib yang mencakup KMeans Clustering untuk identifikasi zona seismik aktif, serta Streamlit Dashboard untuk visualisasi interaktif. Pengujian terhadap dataset USGS yang mencakup 231 record kejadian gempa menghasilkan throughput ingestion sebesar 117,97 record/detik, total latency pipeline 1,86 detik, dan tingkat data bersih 94,81%. KMeans clustering dengan  $k=6$  berhasil mengidentifikasi enam zona seismik berbeda dengan pola kedalaman dan magnitudo yang distinct. Seluruh output analytics tersimpan dalam format JSON terstruktur dan divisualisasikan secara real-time melalui Streamlit Dashboard. Hasil implementasi membuktikan bahwa platform ini memenuhi karakteristik 5V Big Data dan layak dikembangkan ke skala klaster multi-node untuk aplikasi pemantauan seismik nyata.

**Kata Kunci:** Big Data, Apache Kafka, Apache Spark, Spark MLlib, KMeans Clustering, USGS Earthquake Catalog, Seismik Analytics, Streamlit Dashboard, Distributed Computing.

# BAB I

## PENDAHULUAN

### 1.1 Latar Belakang

Indonesia merupakan salah satu wilayah dengan tingkat aktivitas seismik tertinggi di dunia, berada di pertemuan tiga lempeng tektonik utama: Lempeng Eurasia, Indo-Australia, dan Pasifik [13]. Kondisi ini mengakibatkan ribuan kejadian gempa bumi dicatat setiap tahunnya, dari magnitudo kecil hingga gempa destruktif [12]. Data observasi seismik menunjukkan bahwa jumlah kejadian gempa yang tercatat secara global terus meningkat seiring meluasnya jaringan sensor, yang saat ini mencakup lebih dari 150 stasiun seismograf tersebar di seluruh dunia [7], [8].

Permasalahan mendasar yang muncul bukan lagi sekadar "bagaimana memprediksi gempa", melainkan "bagaimana mengelola dan menganalisis volume data seismik yang terus tumbuh secara masif, cepat, dan heterogen" [2], [4]. Pendekatan konvensional berbasis *single-machine*, termasuk model *deep learning* seperti LSTM dan CNN-LSTM yang hanya berjalan di memori lokal satu komputer [3], [14], [15], tidak mampu memenuhi kebutuhan ini karena tidak memiliki kemampuan skalabilitas horizontal dan tidak mengukur metrik performa infrastruktur yang merupakan ciri khas sistem *Big Data* [1].

Konsep *Big Data* dalam seismologi bukan sekadar soal volume data yang besar [6], [9]. Konsep ini mengacu pada ekosistem teknologi terdistribusi yang mampu menangani karakteristik 5V secara serentak: *Volume* (skala data ratusan ribu hingga jutaan *record*), *Velocity* (kecepatan data masuk dari sensor secara *real-time*), *Variety* (keragaman format dan sumber data seperti JSON, CSV, *waveform*), *Veracity* (penanganan *noise* dan anomali data sensor), serta *Value* (transformasi data mentah menjadi informasi yang dapat digunakan untuk mitigasi bencana). Penelitian ini didesain secara khusus untuk memenuhi kelima aspek tersebut melalui *stack* teknologi *Big Data* yang riil [5], [11].

Telah dibuktikan bahwa arsitektur berbasis Apache Kafka dan Apache Flink mampu menangani lebih dari 15.000 aliran data seismik secara bersamaan dengan latensi yang sangat minim [10]. Namun, implementasi tersebut masih sangat bergantung pada infrastruktur khusus. Penelitian ini mengembangkan platform serupa yang lebih aksesibel dengan menggunakan Apache Kafka dan Apache Spark dalam mode lokal yang dapat dijalankan pada perangkat keras biasa, sambil tetap mempertahankan prinsip-prinsip arsitektur *Big Data* yang benar.

### 1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, permasalahan yang diangkat dalam penelitian ini adalah :

1. Bagaimana membangun pipeline Big Data end-to-end yang mampu mengingesti, memproses, dan menganalisis data seismik USGS secara terdistribusi dengan mengukur throughput, latency, dan skalabilitas?
2. Bagaimana melakukan analisis spatio-temporal aktivitas seismik menggunakan Spark MLlib (KMeans Clustering) yang berjalan secara terdistribusi, bukan berbasis single-machine deep learning?
3. Sejauh mana implementasi yang dibangun memenuhi karakteristik 5V Big Data dan bagaimana platform dashboard analytics dapat divisualisasikan secara interaktif?

## **1.3 Tujuan & Kontribusi Penelitian**

### **1.3.1 Tujuan Penelitian**

Tujuan penelitian ini adalah :

1. Membangun dan mengintegrasikan tiga komponen inti Big Data (Apache Kafka, Apache Spark, Hadoop HDFS) dalam satu pipeline yang kohesif untuk pemrosesan data seismik USGS.
2. Mengimplementasikan Spark MLlib KMeans Clustering untuk identifikasi zona seismik aktif secara terdistribusi, menghasilkan profil zona berdasarkan koordinat geografis, kedalaman, dan magnitudo.
3. Mengukur metrik performa infrastruktur Big Data yang sesungguhnya: throughput ingestion (record/detik), processing latency (detik), dan persentase veracity handling.
4. Membangun Streamlit Dashboard interaktif sebagai lapisan visualisasi yang menampilkan output analytics secara real-time.

### **1.3.2 Kontribusi Penelitian**

Kontribusi yang diberikan penelitian ini adalah :

1. Implementasi arsitektur Lambda Architecture yang dapat direproduksi pada hardware standar (PC/laptop), menjembatani gap antara teori Big Data dan implementasi nyata dalam konteks akademik.
2. Bukti empiris bahwa stack Kafka + Spark + HDFS dapat diterapkan untuk analisis seismik dengan karakteristik 5V yang terukur dan terdokumentasi.
3. Dashboard analytics berbasis Streamlit yang mengintegrasikan output Spark MLlib dengan visualisasi interaktif, menjadi contoh konkret penerapan Big Data dalam domain geosains.

## **1.4 Struktur Paper**

Laporan ini disusun dalam enam bab. Bab I membahas pendahuluan mencakup latar belakang, rumusan masalah, tujuan, dan kontribusi penelitian. Bab II menyajikan kajian literatur terhadap 15 jurnal internasional yang diklasifikasikan ke dalam empat tema utama. Bab III menjelaskan metodologi yang mencakup arsitektur sistem, sumber data, pipeline preprocessing, dan metode

analisis berbasis Spark MLlib. Bab IV mendeskripsikan desain eksperimen termasuk skenario pengujian, environment, dan matrik evaluasi. Bab V memaparkan hasil implementasi dengan data nyata dari eksperimen yang telah dijalankan. Bab VI menyimpulkan penelitian dan menjabarkan rencana pengembangan ke depan.

## **BAB II**

### **KAJIAN LITERATUR**

#### **2.1 Tinjauan Studi Terkait**

##### **2.1.1 Arsitektur Pemrosesan Big Data untuk Seismologi**

Dou dan Liu (2021) mengembangkan SeisFLINK berbasis Apache Kafka dan Apache Flink untuk pemrosesan data seismik real-time [10]. Sistem ini mampu menangani lebih dari 15.000 aliran data dan menghasilkan laporan gempa dalam waktu kurang dari dua menit. Penelitian ini mendukung penggunaan Kafka sebagai ingestion layer pada penelitian ini.

Zhao dkk. (2024) menjelaskan bahwa machine learning dalam seismologi mulai beralih ke infrastruktur terdistribusi untuk meningkatkan skalabilitas dan pemrosesan paralel [1]. Temuan ini mendukung penerapan distributed computing dalam penelitian ini

##### **2.1.2 Efisiensi Model Analitik pada Dataset Seismik Berskala Besar**

Dascher-Cousineau dkk. (2023) menunjukkan bahwa model neural network RECAST/GRU memiliki kompleksitas linear dan mampu menangani lebih dari 1.000.000 kejadian gempa secara efisien [7]. Penelitian ini menegaskan pentingnya pemilihan algoritma yang scalable untuk Big Data. Oleh karena itu, penelitian ini menggunakan KMeans dari Spark MLlib karena dapat dijalankan secara terdistribusi dengan kompleksitas yang lebih terkontrol.

##### **2.1.3 Integrasi Data Multimodal**

Hu dkk. (2025) mengembangkan SafeNet yang mengintegrasikan data katalog gempa dan waveform untuk meningkatkan akurasi prediksi [2]. Hou dkk. (2024) juga menggabungkan waveform dan data teks untuk estimasi magnitudo real-time dengan akurasi tinggi [4]. Selain itu, Sadhukhan dkk. (2023) menunjukkan bahwa integrasi data heterogen, seperti parameter seismik dan temperatur global NOAA, dapat meningkatkan performa prediksi [12].

Penelitian lain seperti PreD-Net oleh Convertito dkk. (2024) dan neural encoder oleh Zlydenko dkk. (2023) membuktikan bahwa pendekatan deep learning efektif dalam mengenali pola spasial dan temporal pada data gempa [5][9].

##### **2.1.4 Implementasi untuk Kegempaan Indonesia**

Susandri dkk. (2025) mengevaluasi data gempa Indonesia menggunakan Bidirectional LSTM dan Hybrid CNN-GRU, dengan hasil yang efektif untuk pola temporal dan wilayah berklaster tinggi [13]. Wardhani dkk. (2025) menerapkan K-Means Clustering pada wilayah sesar Palu-Koro dan memperoleh hasil yang baik [14], sehingga mendukung penggunaan KMeans

pada penelitian ini. Selain itu, Kurniawan dkk. (2023) mengembangkan sistem peringatan dini berbasis CNN [15], sedangkan Kumoro dkk. (2024) menunjukkan bahwa metode ARIMA kurang optimal untuk pola gempa yang bersifat non-linear [11].

2.2 Tabel Perbandingan Studi Terdahulu

Tabel 1. Perbandingan studi terdahulu terkait kebencanaan

| No | Penulis & Tahun       | Metode / Teknologi            | Dataset                         | Hasil Utama                                 | Kelebihan & Kekurangan                                                             |
|----|-----------------------|-------------------------------|---------------------------------|---------------------------------------------|------------------------------------------------------------------------------------|
| 1  | Zhao dkk., 2024       | ML Scoping Review             | Berbagai sumber ML seismik      | Tren ML terkini untuk mitigasi gempa        | (+) Komprehensif, landasan teoritis kuat (-)Tidak mengusulkan model baru           |
| 2  | Hu dkk., 2025         | SafeNet (Multimodal FusionNN) | Katalog China & US (50 tahun)   | Ungguli 13 model standar jangka menengah    | (+)Integrasi data heterogen skalabel (-)Kompleksitas fitur sangat tinggi (282 dim) |
| 3  | Muhammad dkk., 2023   | Generalized Deep Learning     | Data seismik regional           | Prediksi fleksibel, berbagai tipe data      | (+)Adaptif untuk berbagai input (-)Rentan overfitting                              |
| 4  | Hou dkk., 2024        | Transformed Mixed Modal       | 5.365 kejadian gempa            | RMSE < 0,38 dalam 3 detik awal gelombang    | (+)Akurasi tinggi real-time (-)Bergantung kecepatan deteksi gelombang              |
| 5  | Convertito dkk., 2024 | PreD-Net (Deep Learning)      | Geysers, Cooper, Basin, Hengill | Identifikasi isnyal prekursor gempa induksi | (+)Generalisasi lintas lokasi baik (-)Akurasi turun pada magnitudo sangat rendah   |
| 6  | Asha dkk., 2025       | LSTM & Neural Networks        | Database USGS                   | LSTM terbaik untuk pola temporal USGS       | (+)Unggul dependensi temporal (-)Kendala akurasi prediksi absolut                  |
| 7  | Dascher-Cousineau.,   | RECAST (Neural STPP)          | Dataset sintesis &              | Kompleksitas linear, skalabel >             | (+)Skalabilitas tinggi dataset besar                                               |

|    |                      |                           |                                   |                                              |                                                                                     |
|----|----------------------|---------------------------|-----------------------------------|----------------------------------------------|-------------------------------------------------------------------------------------|
|    | 2023                 |                           | regional                          | 1Jt event                                    | (-)Kualitas bergantung volume data pelatihan                                        |
| 8  | Dervisi dkk., 2025   | SmaAt-UNet & Earthformer  | Katalog resolusi tinggi otomatis  | Peramalan laju seismisitas jangka pendek     | (+)akurasi tinggi spasio-temporal<br>(-)kebutuhan komputasi sangat besar            |
| 9  | Zlydenko dkk., 2024  | Neural Encoder-Decoder    | Katalog gempa terintegrasi        | +4% informasi vs model ETAS                  | (+)pelajari struktur anisotropik sesar<br>(-)Lebih rumit dari model tradisional     |
| 10 | Dou & Liu., 2021     | SeisFLINK (Kafka & Flink) | Aliran data seismik kontinu       | Rilis laporan < 2 menit, 15.000 aliran       | (+)Latensi rendah, pemrosesan konkuren<br>(-)Infrastruktur Big Data khusus kompleks |
| 11 | Kumoro dkk., 2024    | ARIMA & Uji Statistik     | Data gempa regional               | Analisis prediksi berbasis deret waktu       | (+)Sederhana, interpretabel<br>(-)Gagal tangkap pola non-linear                     |
| 12 | Sadhukhan dkk., 2023 | Bi-LSTM & Transformer     | NOAA + 8 parameter seismik        | Anomali suhu tingkatkan presisi M5-M6        | (+)Integrasi data iklim & seismik<br>(-)Akuisisi data anomali suhu sulit            |
| 13 | Susandri dkk., 2025  | CNN, LSTM, Hybrid CNN-GRU | 117.251 event Indonesia 2008-2024 | BiLSTM $R^2=0,653$ , CNN-GRU baik di klaster | (+)khusus konteks Indonesia<br>(-)Belum skala ke infrastruktur Big Data             |
| 14 | Wardhani dkk., 2025  | K-Means + LSTM            | Sesar Palu-Koro & Matano          | MSE klaster berbeda 0,379, zona              | (+)Clustering zona seismik efektif<br>(-)Belum integrasi pipeline Big Data          |
| 15 | Kurniawan dkk., 2023 | CNN Early Warning         | Data P-wave Jakarta-Bandung       | CNN deteksi P-wave dalam 1-3 detik           | (+)aplikatif untuk EWS real-time<br>(-)Terbatas satu wilayah                        |



## **2.3 Research Gap & Posisi Penelitian**

### **2.3.1 Research Gap**

Berdasarkan sintesis 15 jurnal di atas, terdapat tiga celah penelitian yang signifikan. Pertama, sebagian besar penelitian masih memisahkan aspek infrastruktur Big Data dari aspek analitik. Studi yang menggunakan deep learning (LSTM, CNN, Transformer) umumnya tidak mengukur throughput, latency, dan skalabilitas infrastruktur, sehingga tidak mencerminkan karakteristik nyata sistem Big Data. Kedua, implementasi Big Data untuk seismologi seperti SeisFLINK [10] yang paling relevan bergantung pada infrastruktur enterprise (Apache Flink, cluster khusus) yang tidak terjangkau untuk penelitian akademik standar. Ketiga, belum ada penelitian yang mengintegrasikan pipeline Kafka-Spark end-to-end dengan dashboard visualisasi interaktif yang dapat didemonstrasikan secara live dalam konteks akademik.

### **2.3.2 Posisi Penelitian**

Berdasarkan sintesis 15 jurnal di atas, terdapat tiga celah penelitian yang signifikan. Pertama, sebagian besar penelitian masih memisahkan aspek infrastruktur Big Data dari aspek analitik. Studi yang menggunakan deep learning (LSTM, CNN, Transformer) umumnya tidak mengukur throughput, latency, dan skalabilitas infrastruktur, sehingga tidak mencerminkan karakteristik nyata sistem Big Data. Kedua, implementasi Big Data untuk seismologi seperti SeisFLINK [10] yang paling relevan bergantung pada infrastruktur enterprise (Apache Flink, cluster khusus) yang tidak terjangkau untuk penelitian akademik standar. Ketiga, belum ada penelitian yang mengintegrasikan pipeline Kafka-Spark end-to-end dengan dashboard visualisasi interaktif yang dapat didemonstrasikan secara live dalam konteks akademik.


## BAB III

### METODOLOGI

#### 3.1 Arsitektur Sistem / Framework

Platform yang dibangun mengadopsi Lambda Architecture yang dimodifikasi untuk keperluan penelitian akademik. Arsitektur ini terdiri dari empat lapisan utama yang saling terhubung secara pipeline :

**Gambar 1.** *Arsitektur Platform Big Data Analytics Gempa USGS*



Alasan pemilihan arsitektur ini adalah kemampuannya untuk memisahkan concerns secara jelas: Kafka menangani aspek Velocity (streaming dan buffering), Spark menangani aspek Volume dan Veracity (pemrosesan terdistribusi dan cleaning), HDFS/Parquet menangani aspek Volume jangka panjang, dan Dashboard menangani aspek Value (presentasi hasil kepada pengguna). Pemisahan ini memungkinkan setiap komponen dioptimalkan secara independen.

#### 3.2 Sumber Data & Pengumpulan Data

Dataset yang digunakan adalah USGS Earthquake Catalog yang diunduh dari <https://earthquake.usgs.gov/earthquakes/search/>. Dataset ini mencakup kejadian gempa bumi seluruh dunia dengan 22 atribut per record, termasuk koordinat spasial, kedalaman, magnitudo, tipe magnitudo, kualitas sinyal, dan metadata sensor. Untuk penelitian ini digunakan data periode Mei 2026 sebagai demonstrasi pipeline, dengan total 231 record mentah.

**Tabel 2.** Pemetaan karakteristik 5V Big Data dalam implelementasi

| Dimensi  | Nilai dalam Dataset                                                                     | Implementasi Teknis                                                                                                                                                                                                                  |
|----------|-----------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Volume   | 231 record (demonstrasi); dapat mencapai jutaan record untuk rentang multi-tahun        | Apache Kafka menampung seluruh dataset di topic 'gempa-stream'. HDFS/Parquet menyimpan data bersih. Format Parquet efisien 3-10x dibanding CSV untuk query kolom tertentu.                                                           |
| Velocity | Throughput 117,97 rec/det (diukur nyata)                                                | Kafka Producer mengirim data secara bulk dengan kompresi GZIP dan batching. Throughput dan latency diukur menggunakan modul time Python dan disimpan ke ingestion_metrics.json.                                                      |
| Variety  | 22 atribut per record; 4 tipe data berbeda (numerik, string, timestamp, koordinat)      | Schema Spark StructType mendefinisikan 18 field dengan tipe DoubleType, StringType. Feature engineering menambahkan kolom turunan: year, month, hour, mag_category, depth_category.                                                  |
| Veracity | 12 record anomali terdeteksi (5,19% dari total)                                         | Spark filtering: dropna() pada kolom kritis (latitude, longitude, mag, depth), filter type='earthquake', filter $\text{mag} \geq 0$ , $\text{depth} \geq 0$ , $\text{rms} \leq 2.0$ , dropDuplicates() berdasarkan (time, lat, lon). |
| Value    | 6 zona seismik teridentifikasi; statistik deskriptif komprehensif; dashboard interaktif | Spark MLlib KMeans menghasilkan profil zona seismik. Spark SQL menghasilkan distribusi magnitudo, aktivitas temporal, dan hotspot grid. Semua output disajikan via Streamlit Dashboard.                                              |

### 3.3 Pipeline Data & Preprocessing

Pipeline data terdiri dari tiga skrip Python yang dieksekusi secara sekuensial, masing-masing merepresentasikan satu layer dalam arsitektur :

#### 3.3.1 Tahap 1: Ingestion Layer (producer.py)

Producer.py membaca file CSV dataset USGS menggunakan pandas, kemudian melakukan normalisasi nama kolom (handling perbedaan kapitalisasi dari berbagai versi API USGS). Setiap

record dibangun menjadi payload JSON terstruktur dengan 11 field dan dikirimkan ke Kafka topic 'gempa-stream' menggunakan KafkaProducer dengan konfigurasi batch\_size=65.536 bytes, linger\_ms=10, dan compression\_type='gzip'. Mode fallback tersedia jika Kafka tidak terhubung, dengan data disimpan ke buffer lokal. Metrik throughput dan latency dihitung menggunakan modul time dan disimpan ke ingestion\_metrics.json.

### 3.3.2 Tahap 2: Processing Layer (Spark pipeline.py)

Spark pipeline.py menginisialisasi SparkSession dengan konfigurasiAppName='BigData\_Gempa\_USGS\_Platform' dan local[\*] untuk memanfaatkan seluruh core CPU. Data dibaca dari CSV menggunakan explicit schema StructType (18 field) untuk konsistensi parsing. Data cleaning (Veracity Handling) dilakukan melalui serangkaian filter: filter type='earthquake', dropna() pada kolom kritis, filter nilai negatif, filter rms $\leq$ 2.0, dan dropDuplicates() berbasis kombinasi (time, latitude, longitude). Feature engineering menambahkan kolom tahun/bulan/jam dari timestamp, serta kategorisasi magnitudo (Minor/Light/Moderate/Strong/Major) dan kedalaman (Dangkal/Menengah/Dalam). Analytics dilakukan melalui Spark groupBy dan aggregate untuk distribusi, temporal trend, dan hotspot grid.

### 3.3.3 Tahap 3: KMeans Clustering (Spark MLlib)

KMeans Clustering dijalankan menggunakan pipeline Spark MLlib yang terdiri dari tiga stage: VectorAssembler untuk menggabungkan empat fitur (latitude, longitude, depth, mag) menjadi vektor, StandardScaler untuk normalisasi (withMean=True, withStd=True), dan KMeans dengan k=6, seed=42, maxIter=20. Pipeline ini berjalan secara terdistribusi di atas Spark DataFrame. Hasil clustering (6 cluster zona seismik) disimpan bersama semua analytics lainnya ke spark\_output/analytics\_results.json.

## 3.4 Metode Analisis / Model

Metode analisis yang diimplementasikan dalam penelitian ini berpusat pada Spark MLlib dan Spark SQL, bukan deep learning. Keputusan ini disengaja untuk memastikan seluruh komputasi berjalan secara terdistribusi di atas Spark Engine.

**Tabel 3.** *Metode Analisis Berbasis Spark*

| Modul                   | Metode                | Library                   | Output yang Dihasilkan                                                                |
|-------------------------|-----------------------|---------------------------|---------------------------------------------------------------------------------------|
| Statistik Deskriptif    | Aggregation & GroupBy | Spark SQL / DataFrame API | Rata-rata, maks, min, std magnitudo; distribusi per kategori; hotspot grid 1°×1°      |
| Clustering Zona Seismik | KMeans (k=6)          | Spark MLlib               | 6 profil zona: koordinat pusat, jumlah event, avg/maks magnitudo, rata-rata kedalaman |

|                   |                           |                                      |                                                                                         |
|-------------------|---------------------------|--------------------------------------|-----------------------------------------------------------------------------------------|
| Analisis Temporal | Time-series Aggregation   | Spark SQL<br>(year/month<br>groupBy) | Tren jumlah kejadian per bulan/tahun, rata-rata dan maksimum magnitudo per periode      |
| Analisis Spasial  | Grid-based Hotspot        | Spark DataFrame +<br>round()         | Top 200 grid 1°×1° terpadat, event count dan avg magnitudo per sel grid                 |
| Dashboard         | Interactive Visualization | Streamlit +<br>Plotly + Folium       | Peta heatmap, scatter plot cluster, bar chart distribusi, time-series chart, metrik KPI |

## BAB IV

### DESAIN EKSPERIMEN

#### 4.1 Skenario Eksperimen

Eksperimen dirancang untuk membuktikan dua hal secara bersamaan: bahwa platform yang dibangun benar-benar mencerminkan karakteristik Big Data (bukan sekadar data besar di single-machine), dan bahwa analytics yang dihasilkan memiliki makna untuk domain seismologi. Tiga skenario utama dijalankan.

1. Skenario Ingestion Benchmark: Producer.py dijalankan untuk mengukur throughput (record/detik) saat mengirim 231 record ke Kafka. Metrik yang dicatat: total record, duration, throughput, data loss, dan estimated MB.
2. Skenario Pipeline Processing: Spark pipeline.py dijalankan untuk mengukur latency per tahap (ingestion CSV, cleaning, analytics, clustering) dan total latency pipeline. Metrik yang dicatat: raw records, clean records, dropped records, waktu per tahap, throughput Spark.
3. Skenario Analytics & Clustering: KMeans dengan  $k=6$  dijalankan pada data bersih untuk mengidentifikasi zona seismik. Profil setiap cluster (koordinat pusat, jumlah event, magnitudo rata-rata) dievaluasi terhadap pengetahuan geografis yang ada tentang zona seismik aktif.

#### 4.2 Baseline / Pembanding

Sebagai pembanding, penelitian ini menggunakan pendekatan Deep Learning berbasis TensorFlow/Keras (CNN-LSTM) yang berfokus pada prediksi nilai gempa menggunakan komputasi pada satu mesin. Berbeda dengan pendekatan tersebut, platform yang dikembangkan menerapkan Big Data Analytics berbasis Apache Spark dan Kafka yang mendukung pemrosesan data secara paralel, penyimpanan terstruktur dalam format Parquet/HDFS, serta analisis multidimensi seperti distribusi data, clustering wilayah, hotspot spasial, dan tren temporal. Selain menghasilkan insight yang lebih beragam, platform ini juga memenuhi karakteristik 5V Big Data (Volume, Velocity, Variety, Veracity, dan Value) serta memiliki kemampuan skalabilitas yang lebih baik untuk pengolahan data dalam jumlah besar.

#### 4.3 Environment Eksperimen

**Tabel 4.** *Spesifikasi Environment Eksperimen*

| Komponen         | Spesifikasi                                                                                                        |
|------------------|--------------------------------------------------------------------------------------------------------------------|
| Hardware / Cloud | PC / Laptop Intel Core i7 Generasi 11, RAM 16 GB, NVIDIA RTX 3050 4 GB (GPU tidak digunakan untuk analytics Spark) |
| Sistem Operasi   | Windows 10/11 64-bit atau Ubuntu 20.04 LTS                                                                         |

|                    |                                                                                                                                                                          |
|--------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Framework Big Data | Apache Kafka 3.x untuk data ingestion, Apache Spark 3.4 (mode local[*]) untuk pemrosesan data, Hadoop HDFS 3.x sebagai penyimpanan terdistribusi (opsional)              |
| Bahasa Pemrograman | Python 3.9+                                                                                                                                                              |
| Library / Tools    | PySpark, kafka-python, findspark, Spark MLlib (KMeans, VectorAssembler, StandardScaler), Pandas, Streamlit, Plotly, Folium                                               |
| Dataset            | USGS Earthquake Catalog unduh dari <a href="https://earthquake.usgs.gov/earthquakes/search/">https://earthquake.usgs.gov/earthquakes/search/</a> (format CSV, ~22 kolom) |

#### 4.4 Metrik Evaluasi

Penelitian ini menggunakan dua kategori metrik yang keduanya wajib dilaporkan untuk membuktikan aspek Big Data secara menyeluruh :

##### 4.4.1 Metrik Infrastruktur Big Data

- Throughput Ingestion (record/detik): jumlah record yang berhasil dikirim ke Kafka per satuan waktu mencerminkan kapasitas Velocity layer.
- Processing Latency (detik): waktu total dari pembacaan data hingga penyimpanan ke Parquet mencerminkan efisiensi pipeline end-to-end.
- Veracity Rate (%): persentase data anomali yang berhasil diidentifikasi dan dibuang — mencerminkan kualitas data cleaning.
- Data Throughput Spark (record/detik): jumlah record bersih yang diproses per detik oleh Spark engine.

##### 4.4.2 Metrik Analytics

- Profil Cluster KMeans: koordinat pusat, jumlah event, rata-rata magnitudo, dan rata-rata kedalaman per cluster menilai kemampuan identifikasi zona seismik.
- Distribusi Kategori Magnitudo: proporsi Minor/Light/Moderate/Strong/Major menilai representativitas dataset.
- Konsistensi Hotspot Spasial: kesesuaian antara grid hotspot yang terdeteksi dengan pengetahuan geografis zona seismik aktif yang diketahui.

## BAB V

### HASIL

#### 5.1 Hipotesis Hasil

Berdasarkan rancangan sistem Big Data yang telah diimplementasikan dan kajian literatur terkait, berikut hipotesis hasil yang dirumuskan untuk masing-masing pengujian:

**Tabel 5.** *Hipotesis hasil penelitian*


| Kode | Hipotesis                                                                          | Hasil yang Diharapkan                                                                          |
|------|------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------|
| H1   | Pipeline Apache Kafka dan Apache Spark mampu memproses data seismik secara efisien | Sistem menghasilkan throughput tinggi dengan latency rendah                                    |
| H2   | Data cleaning menggunakan Spark mampu meningkatkan kualitas dataset                | Data anomali berhasil difilter sehingga data lebih valid dan konsisten                         |
| H3   | KMeans Clustering pada Spark MLlib mampu mengidentifikasi pola aktivitas seismik   | Cluster yang terbentuk sesuai dengan zona aktif tektonik dunia                                 |
| H4   | Streamlit Dashboard mampu menampilkan hasil analytics secara interaktif            | Visualisasi data dan performa pipeline dapat dipantau secara real-time                         |
| H5   | Integrasi Kafka, Spark, dan HDFS/Parquet memenuhi karakteristik 5V Big Data        | Aspek Volume, Velocity, Variety, Veracity, dan Value dapat dibuktikan melalui hasil eksperimen |

#### 5.2 Visualisasi Hasil


Visualisasi hasil dilakukan menggunakan Streamlit Dashboard yang menampilkan berbagai analytics secara interaktif dan real-time. Dashboard menampilkan peta persebaran gempa berbasis koordinat geografis untuk mempermudah identifikasi wilayah dengan aktivitas seismik tinggi. Selain itu, tersedia visualisasi clustering KMeans yang menunjukkan pengelompokan zona seismik berdasarkan kemiripan karakteristik magnitudo, kedalaman, dan lokasi gempa. Dashboard juga dilengkapi grafik distribusi magnitudo, tren aktivitas gempa berdasarkan waktu, serta metrik performa pipeline seperti throughput dan latency. Visualisasi ini membantu pengguna memahami pola aktivitas seismik secara lebih cepat, informatif, dan mudah dianalisis.



**Gambar 2. Dashboard Visualisasi Aktivitas Gempa Bumi**



**Gambar 3. Visualisasi Clustering Zona Seismik**



### 5.3 Kontribusi yang Diharapkan

Penelitian ini memberikan kontribusi akademik, teknis, dan praktis dalam pengembangan platform Big Data untuk analisis aktivitas seismik. Secara akademik, penelitian ini menyediakan implementasi Lambda Architecture berbasis Apache Kafka, Apache Spark, dan Hadoop HDFS yang dapat direproduksi pada hardware standar sehingga dapat menjadi referensi pembelajaran dan penelitian lanjutan di bidang Big Data geosains. Secara teknis, penelitian ini menghasilkan pipeline ingestion, processing, storage, serta analisis clustering berbasis Spark MLlib yang berjalan secara terdistribusi dan mendukung pengolahan data seismik secara efisien. Selain itu, secara praktis, Streamlit Dashboard yang dikembangkan mampu menyajikan visualisasi interaktif aktivitas seismik secara real-time sehingga berpotensi membantu proses monitoring dan mitigasi bencana gempa di masa mendatang.

## **BAB VI**

### **KESIMPULAN & RENCANA PENGEMBANGAN**

#### **6.1 Kesimpulan**

Penelitian ini berhasil membangun platform Big Data Analytics end-to-end untuk monitoring dan analisis aktivitas seismik menggunakan data dari USGS Earthquake Catalog. Platform mengintegrasikan Apache Kafka sebagai data ingestion, Apache Spark sebagai engine pemrosesan terdistribusi, serta Hadoop HDFS/Parquet sebagai media penyimpanan dalam satu pipeline yang terintegrasi. Berbeda dengan pendekatan deep learning berbasis TensorFlow yang berjalan pada satu proses komputasi, seluruh proses analitik pada penelitian ini dijalankan menggunakan Spark Engine yang mendukung pemrosesan paralel dan skalabilitas yang lebih baik.

Hasil pengujian menunjukkan performa sistem yang baik dengan throughput sebesar 117,97 record/detik, total latency pipeline sebesar 1,8565 detik, dan tingkat veracity data sebesar 94,81%. Selain itu, metode KMeans Clustering berhasil mengidentifikasi enam zona seismik utama dengan karakteristik geografis yang berbeda. Dashboard interaktif berbasis Streamlit juga berhasil menyajikan visualisasi dan analisis data secara informatif melalui fitur eksplorasi magnitudo, kedalaman, lokasi, dan periode waktu. Secara keseluruhan, platform yang dibangun telah memenuhi karakteristik 5V Big Data (Volume, Velocity, Variety, Veracity, dan Value) serta mampu menghasilkan insight yang mendukung pemantauan aktivitas gempa bumi.

#### **6.2 Keterbatasan (Limitations)**

Penelitian ini masih memiliki beberapa keterbatasan. Dataset yang digunakan hanya mencakup 231 record sehingga belum merepresentasikan skala Big Data yang sesungguhnya. Apache Spark masih dijalankan pada mode local[\*] sehingga belum memanfaatkan cluster multi-node, sedangkan Apache Kafka masih menggunakan single broker tanpa mekanisme replikasi. Selain itu, jumlah cluster pada algoritma KMeans ditentukan berdasarkan pertimbangan interpretasi geografis dan belum melalui proses optimasi parameter secara sistematis.

#### **6.3 Rencana Pengembangan (Future Work)**

Pengembangan selanjutnya dapat difokuskan pada penggunaan dataset USGS dengan rentang waktu yang lebih panjang untuk meningkatkan skala data dan kompleksitas analisis. Selain itu, implementasi Spark pada lingkungan cluster multi-node dan Kafka multi-broker dapat dilakukan untuk meningkatkan skalabilitas serta fault tolerance sistem. Pengembangan lain yang dapat dilakukan adalah penerapan Spark Structured Streaming untuk analisis data secara near real-time dan integrasi data BMKG sebagai sumber data tambahan guna memperkaya cakupan analisis aktivitas seismik di Indonesia.

## DAFTAR PUSTAKA

- [1] Y. Zhao, S. Lv, and P. Liu, "Advances in Earthquake Prevention and Reduction Based on Machine Learning: A Scoping Review," *IEEE Access*, vol. 12, pp. 143908-143929, 2024, doi: 10.1109/ACCESS.2024.3467149.
- [2] Y. Hu et al., "Scalable intermediate-term earthquake forecasting with multimodal fusion neural networks," *Sci. Rep.*, vol. 15, no. 9748, pp. 1-16, Mar. 2025, doi: 10.1038/s41598-025-93877-7.
- [3] D. Muhammad, I. Ahmad, M. I. Khalil, W. Khalil, and M. O. Ahmad, "A Generalized Deep Learning Approach to Seismic Activity Prediction," *Appl. Sci.*, vol. 13, no. 3, p. 1598, Jan. 2023, doi: 10.3390/app13031598.
- [4] B. Hou, Y. Zhou, S. Li, Y. Wei, and J. Song, "Real-time earthquake magnitude estimation via a deep learning network based on waveform and text mixed modal," *Earth Planets Space*, vol. 76, no. 58, pp. 1-18, Apr. 2024, doi: 10.1186/s40623-024-02005-8.
- [5] V. Convertito, F. Giampaolo, O. Amoroso, and F. Piccialli, "Deep learning forecasting of large induced earthquakes via precursory signals," *Sci. Rep.*, vol. 14, no. 2964, pp. 1-17, Feb. 2024, doi: 10.1038/s41598-024-52935-2.
- [6] V. Asha, P. D. V. Devi, A. Shreya, N. Manisha, and K. C. Hasini, "Seismic Shift: Predicting Earthquakes With Deep Learning," in *Proc. ICCSCE 2025*, Springer, 2025, pp. 3005-3017, doi: 10.2991/978-94-6463-858-5\_252.
- [7] K. Dascher-Cousineau, O. Shchur, E. E. Brodsky, and S. Günnemann, "Using deep learning for flexible and scalable earthquake forecasting," *Geophys. Res. Lett.*, vol. 50, no. 17, 2023, doi: 10.1029/2023GL103909.
- [8] F. Dervisi et al., "Towards a deep learning approach for short-term data-driven spatiotemporal seismicity rate forecasting," *Earth Planets Space*, vol. 77, no. 185, pp. 1-15, 2025, doi: 10.1186/s40623-025-02241-6.
- [9] O. Zlydenko et al., "A neural encoder for earthquake rate forecasting," *Sci. Rep.*, vol. 13, no. 12350, pp. 1-8, 2023, doi: 10.1038/s41598-023-38033-9.
- [10] L. Dou and S. Liu, "The application of big data real-time stream processing technology in earthquake rapid report," in *Proc. 7th Int. Conf. ICHCE & SWIDR*, 2021, pp. 907-911, doi: 10.1109/ICHCESWIDR54323.2021.9656449.
- [11] R. N. Kumoro, A. S. Fattima, W. H. Susatyo, and D. R. Fudholi, "Analysis and Prediction of the Occurrence of an Earthquake Using ARIMA and Statistical Tests," *IJCCS*, vol. 18, no. 1, pp. 11-20, Jan. 2024, doi: 10.22146/ijccs.85197.
- [12] B. Sadhukhan, S. Chakraborty, S. Mukherjee, and R. K. Samanta, "Climatic and seismic data-driven deep learning model for earthquake magnitude prediction," *Front. Earth Sci.*, vol. 11, 1082832, Feb. 2023, doi: 10.3389/feart.2023.1082832.

- [13] S. Susandri, F. B. Nasution, F. Fajrizal, and Saparudin, "Spatial-Temporal Analysis of Earthquakes in Indonesia with Deep Learning Models," *J. RESTI*, vol. 9, no. 5, pp. 1020-1029, Oct. 2025, doi: 10.29207/resti.v9i5.6538.
- [14] T. P. M. Wardhani et al., "Deep learning approach in seismology: Enhancing earthquake forecasting using K-means clustering and LSTM networks," *J. Inf. Commun. Technol.*, vol. 24, no. 1, pp. 29-51, 2025, doi: 10.32890/jict2025.24.1.2.
- [15] M. A. Kurniawan, S. K. Wijaya, and N. R. Hanifa, "Convolutional Neural Network for Earthquake Ground Motion Prediction Model in Earthquake Early Warning System in West Java," *J. Penelitian Pendidikan IPA*, vol. 9, no. 11, pp. 1004-1010, 2023, doi: 10.29303/jppipa.v9i11.3514.

## LAMPIRAN


### Lampiran A : Pembagian Tugas & Kontribusi Anggota

*Tabel 6. Pembagian tugas & kontribusi anggota*

| No | Nama-NIM                               | Bagian yang Dikerjakan                                                                                                           | Kontribusi (%) | Paraf |
|----|----------------------------------------|----------------------------------------------------------------------------------------------------------------------------------|----------------|-------|
| 1  | Nabila Ramadhani Mujahidin - 123140062 | BAB I Pendahuluan, BAB II Kajian Literatur, penyusunan Research Gap dan referensi penelitian                                     | 15%            |       |
| 2  | Annisa Salsabila - 123140070           | Implementasi Producer.py (Ingestion Layer - Apache Kafka), pengujian throughput dan latency, penyusunan BAB IV Desain Eksperimen | 15%            |       |
| 3  | Willy Syifa Luthfia - 123140071        | BAB III Metodologi, perancangan arsitektur sistem, pipeline data dan preprocessing                                               | 15%            |       |
| 4  | Roberto Charlos Sagala - 123140113     | Implementasi Spark Pipeline.py (Processing Layer), data cleaning, feature engineering, dan penyimpanan output analytics          | 15%            |       |
| 5  | Brahmantio Abimayu - 123140122         | Implementasi K-Means Clustering (Spark MLlib), analisis hasil clustering, dan penyusunan BAB V Hasil                             | 15%            |       |
| 6  | Zacky Khozi Al Miqdad - 123140130      | Pembangunan Streamlit Dashboard, visualisasi interaktif, serta penyusunan BAB VI Kesimpulan dan Rencana Pengembangan             | 15%            |       |
| 7  | Albi R. Suseno - 120140095             | Mencari 2 jurnal saja                                                                                                            | 10%            |       |


## Lampiran B : Mockup / Wireframe Dashboard

**Gambar 4. Dashboard Utama Aktivitas Gempa**




Dashboard utama menampilkan ringkasan aktivitas gempa bumi secara real-time, meliputi total data gempa, rata-rata magnitudo, throughput pipeline, dan distribusi wilayah aktif.

**Gambar 5. Visualisasi Persebaran Gempa Dunia**




Peta persebaran gempa digunakan untuk memvisualisasikan lokasi kejadian gempa berdasarkan koordinat geografis sehingga mempermudah identifikasi hotspot seismik.

**Gambar 6. Visualisasi Clustering Zona Seismik**




Hasil clustering KMeans divisualisasikan untuk menunjukkan pengelompokan wilayah berdasarkan magnitudo, kedalaman, dan lokasi aktivitas gempa.

**Gambar 7. Distribusi Magnitudo Gempa**




Grafik distribusi magnitudo membantu menganalisis proporsi kategori gempa mulai dari Minor hingga Major.

**Gambar 8. Analisis Temporal Aktivitas Gempa**



Visualisasi temporal menunjukkan tren aktivitas gempa berdasarkan waktu untuk melihat pola peningkatan maupun penurunan aktivitas seismik.

**Gambar 9. Monitoring Kinerja Pipeline Big Data**



Dashboard menampilkan metrik performa seperti throughput ingestion, processing latency, dan jumlah data bersih hasil preprocessing.

## Lampiran C : Detail Spesifikasi Teknis Tambahan

Lampiran ini menjelaskan spesifikasi teknis tambahan dari implementasi platform Big Data Analytics aktivitas gempa bumi berbasis Apache Kafka, Apache Spark, dan Streamlit Dashboard.



**Tabel 7.** *Detail spesifikasi teknis tambahan*

| Komponen                   | Detail Implementasi                                                                                                                |
|----------------------------|------------------------------------------------------------------------------------------------------------------------------------|
| Bahasa Pemrograman         | Python 3.9 digunakan sebagai bahasa utama untuk seluruh pipeline sistem.                                                           |
| Apache Kafka               | Digunakan sebagai message broker untuk proses ingestion data streaming dengan topic bernama 'gempa-stream'.                        |
| Apache Spark               | Digunakan sebagai distributed processing engine berbasis PySpark untuk data cleaning, analytics, dan clustering.                   |
| Spark MLlib                | Digunakan untuk implementasi algoritma KMeans Clustering dengan konfigurasi 6 cluster zona seismik.                                |
| Penyimpanan Data           | Data hasil preprocessing disimpan dalam format Parquet dan JSON untuk meningkatkan efisiensi query serta kompatibilitas analytics. |
| Streamlit Dashboard        | Digunakan untuk membangun dashboard interaktif berbasis web yang menampilkan visualisasi analytics secara real-time.               |
| Library Tambahan           | Pandas, NumPy, Plotly, Folium, kafka-python, findspark, dan scikit-learn.                                                          |
| Konfigurasi Kafka Producer | <code>batch_size = 65536 bytes, linger_ms = 10, compression_type = gzip.</code>                                                    |
| Konfigurasi Spark          | Spark berjalan pada mode <code>local[*]</code> sehingga dapat memanfaatkan seluruh core CPU yang tersedia.                         |
| Dataset                    | Dataset berasal dari USGS Earthquake Catalog dengan total 231 record dan sekitar 22 atribut utama.                                 |